Diplôme d'Université
Big data, Data science
Analyse des risques sous Python

Projets tuteurés 2025/26 DU BDAP

Contacter votre tuteur au démarrage du projet (fin février au plus tard)

Groupe de 3 étudiants (max)

Rendu des projets : 30 juin 2025 au plus tard (sauf Big data 30 avril 2026)

Mettre le nom de votre tuteur dans le google doc : Lien

Econométrie : contact samuel.STOCKSIEKER@univ-amu.fr

- **Pour ceux qui souhaitent réaliser leur projet en économétrie : 1 sujet à choisir parmi les 5 projets suivants :**
- **Accidents de la circulation** : Modélisation du niveau de gravité des accidents corporels de la circulation routière (classification supervisé)
- **Fremortorclaim** : modélisation de la charge de sinistre automobile d'un assureur français (régression)
- **Telematics** : modélisation de la charge de sinistre automobile d'un assureur français en intégrant des variables liées au comportement de conduite (régression / classification supervisé)
- **Impact climatique Sinistralité** : modélisation de la charge de sinistre automobile d'un assureur français en intégrant des variables liées au climat (régression / classification supervisé)
- **Risque climatique** : impact du climat sur le risque Incendie du produit Multirisque Agricole (classification supervisée)

- **Livrables**

=> Traitement de données
=> Analyse exploratoire (y compris réduction de dimension et classification non supervisée)
=> Apprentissage supervisée : paramétrique (économétrie) + non paramétrique (machine learning)
=> Code python (notebook avec code et interprétations des résultats)

- **Données** disponibles dans l'AMU Box de Samuel :

Diplôme d'Université
Big data, Data science
Analyse des risques sous Python

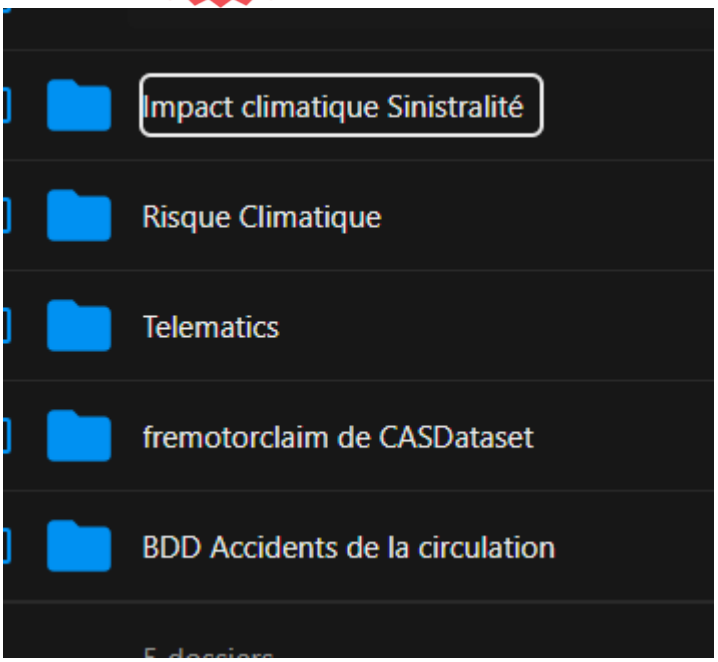

Réseaux de neurones : contact Gilles Michel : gilles-roger.michel@umontpellier.fr

Récupération sur Yahoo Finances ou tout autre site de finance, par API, des cours de clôture d'une liste d'actions contenues dans un fichier CSV (au moins 5 actions), entre le 1er janvier et le 31 décembre 2024. Stocker ces cours dans une base de données. Entraîner un réseau de neurones sur la période du 01/01/2025 au 31/08/2025 pour prédire le cours ou le sens d'évolution de chaque action du 01/09/2025 au 31/12/2025. Générer un fichier CSV par action représentant une simulation de trading sur la période du 01/09/2025 au 31/12/2025 avec une base de 1 million d'euros par action au 01/09/2025. On prendra des frais de broker de 0.01€.

Web scraping : contact Gilles Michel : gilles-roger.michel@umontpellier.fr

Générer un comparateur de prix sur un type de produit choisi par le groupe d'étudiants. Il s'agira de répertorier et analyser les pages web d'au moins 3 sites différents vendant un même type de produits (il faudra s'assurer qu'il y a au moins quelques articles en commun vendus sur plusieurs des sites choisis). Les articles concernés seront classés par catégorie et stockés dans une base de données. L'application python permettra de saisir une référence produit et les différents prix/sites de vente seront affichés après récupération des informations en temps réel par web scraping. Possibilité de publier les informations sur une page web via un service web type Flask.

Diplôme d'Université
Big data, Data science
Analyse des risques sous Python

Détection de Fraude : Alfred Mbairadjim Moussa, mbairadjim.alfred@gmail.com

Le risque de fraude est omniprésent dans le commerce numérique. Pour les entreprises qui utilisent la publicité en ligne, la fraude au clic peut être particulièrement massive et engendrer des taux de clics faussés ainsi qu'une perte d'argent. Les médias publicitaires peuvent par exemple facilement augmenter leurs revenus au coût par clic en cliquant simplement un grand nombre de fois sur l'annonce. Avec plus d'un milliard d'appareils mobiles intelligents en utilisation active tous les mois, la Chine est le plus grand marché mobile du monde et souffre donc d'énormes volumes de trafic frauduleux. Talking Data est la plus grande plateforme indépendante de services Big Data en Chine, couvrant plus de 70% des appareils mobiles actifs dans tout le pays. Ils traitent 3 milliards de clics par jour, dont 90% sont potentiellement frauduleux. Leur approche actuelle pour empêcher la fraude au clic, pour les développeurs d'applications, consiste à mesurer le parcours du clic d'un utilisateur sur leur portefeuille et à signaler les adresses IP qui génèrent un grand nombre de clics, sans jamais installer d'applications. Avec cette information, ils ont construit une liste noire d'adresses IP et de périphériques. Bien que cette technique fonctionne, ils souhaitent garder une longueur d'avance sur les fraudeurs et ont ainsi décidé de se tourner vers les techniques de la Data Science et d'Intelligence Artificielle pour obtenir de l'aide dans le développement de solutions plus innovantes. Il est important de noter que ce problème a été traité par de nombreux Data Scientists à travers le monde (un concours a été d'ailleurs été lancé sur la communauté Kaggle) et de nombreuses solutions sont présentées sur internet. L'objectif de ce projet n'est pas de reprendre une de ces solutions mais plutôt de mettre en œuvre les outils de re-sampling étudiées en cours avant de mettre en place des algorithmes de Machine Learning simplement interprétables. L'ambition serait d'aller plus loin en détectant des réseaux de fraudeurs avec des méthodes adéquates (non abordées en cours).

Livrables:

1-Le notebook Python final

2-Une description détaillée des méthodes utilisées et l'historique du workflow c'est-à-dire le feature Engineering (recherche de variables/paramètres explicatifs), le réglage des hyper-paramètres, les méthodes de validations...

Compression d'images : contact Stéphane Mussard : stephane.mussard@unimes.fr

Utiliser l'ACP ou une autre technique de compression pour réaliser de la compression d'images. Etudier la qualité de la compression en fonction du nombre de composantes principales mobilisées et en fonction du bruit présent dans l'image. Pour cela des classifieurs standards seront mobilisés afin d'étudier la qualité des prédictions sur les images compressées. Des réseaux de type CNN pourront aussi être utilisés pour la classification.

Dataset : MNIST ou autres data (à voir)

Livrable : code python, notebook (POO)

Diplôme d'Université
Big data, Data science
Analyse des risques sous Python

Textmining : contact Stéphane Mussard : stephane.mussard@unimes.fr
Sur la base de décisions de justice (préalablement annotées par un juriste), la tâche consistera à appliquer un simple TF-IDF pour entrainer un classifieur qui permettra de prédire la décision d'un juge. Il s'agira ensuite d'entrainer un Transformers afin de comparer la qualité des prédictions obtenues avec le TF-IDF.
Dataset : Décisions de justice annotées (dataset disponible)
Livrable : code python, notebook (POO)

Projets pour les PhD, Professionnels ou formation continue

- ⇨ Projet spécifique : contacter : stephane.mussard@unimes.fr
- ⇨ Rapport de stage pour ceux qui effectuent un stage, contacter : stephane.mussard@unimes.fr